

基于多任务学习的草地生物量智能预测系统

CSIRO - Image2Biomass Prediction

小组 10

华东师范大学

2026-1-8

—

小组成员

- 俞骞: 模型结构设计，实验验证工作
- 丁乙: 数据划分策略,过拟合对抗系统设计,PPT 编排
- 张建夫: 预训练模型选择

— 小组成员

- 1. 项目介绍 3
 - 1.1 核心算法框架 4
 - 1.2 模型架构：ConvNeXt + 多任务头 5
 - 1.3 损失函数与优化策略 7
 - 1.4 训练策略与集成学习 8
 - 1.5 算法性能验证 9
 - 1.6 结果展示 10
 - 1.7 算法创新点总结： 16

1. 项目介绍

1. 项目介绍

大家好，我们小组的项目是草地生物量智能预测系统。今天我将重点介绍我们的算法实现，包括多任务学习框架、模型架构和优化策略。

问题定义： 单输入（卫星图像）→多输出（5 个生物量指标）

1. 项目介绍

— 1.1 核心算法框架

我们的核心是多任务学习框架。模型同时学习 5 个生物量预测主任务和 4 个辅助任务，包括 NDVI 预测、草高预测、地区分类和草种分类。所有任务共享底层特征，这带来了正则化效果，提升了模型的泛化能力。

问题定义： 单输入（卫星图像）→多输出（5 个生物量指标）

核心思想： 共享特征+多任务头，提升学习效率和泛化能力

1. 项目介绍

— 1.1 核心算法框架

我们的核心是多任务学习框架。模型同时学习 5 个生物量预测主任务和 4 个辅助任务，包括 NDVI 预测、草高预测、地区分类和草种分类。所有任务共享底层特征，这带来了正则化效果，提升了模型的泛化能力。

1.1 核心算法框架

问题定义： 单输入（卫星图像）→多输出（5 个生物量指标）

核心思想： 共享特征+多任务头，提升学习效率和泛化能力

数学表达： 总损失 = 主任务损失 + $0.3 \times$ 辅助任务损失

1. 项目介绍

— 1.1 核心算法框架

我们的核心是多任务学习框架。模型同时学习 5 个生物量预测主任务和 4 个辅助任务，包括 NDVI 预测、草高预测、地区分类和草种分类。所有任务共享底层特征，这带来了正则化效果，提升了模型的泛化能力。

模型架构：

主干网络选择： ConvNeXt-Base

共享特征层设计： 1024→512 的两层全连接网络

多任务头架构： 5 个独立任务头（1 个主任务+4 个辅助任务）

1. 项目介绍

— 1.2 模型架构：ConvNeXt + 多任务头

我们选择了 ConvNeXt 作为主干网络，它结合了 CNN 的高效性和现代架构设计。特征提取层为所有任务共享，然后分别进入不同的任务头。这种设计既减少了参数冗余，又让各任务能够互相促进。这里的主任务头是 5 个生物量指标的回归预测 辅助任务头包括 NDVI 植被指数预测（回归）草高预测（回归）地区分类（分类）草种分类（分类）




图 1 多任务头架构

关键算法：

1. 加权 MSE 损失
2. Mixup 数据增强
3. 测试时增强（TTA）

```
def mixup_data(x, y, alpha=0.2):  
    lam = np.random.beta(alpha, alpha)  
    mixed_x = lam * x + (1 - lam) * x[index, :]  
    y_a, y_b = y, y[index]  
    return mixed_x, y_a, y_b, lam
```

图 2 Mixup 数据增强

1. 项目介绍

— 1.3 损失函数与优化策略

我们设计了加权 MSE 损失函数，给重要的总生物量指标更高的权重。训练中使用了 Mixup 数据增强，混合图像和标签来增强模型鲁棒性。推理时采用测试时增强，通过多个变换的预测结果取平均，提升最终精度。

关键技术点：

- 1. 五折交叉验证：
- 2. 早停与学习率调度
- 3. 模型集成

```
scheduler = ReduceLROnPlateau(optimizer, mode='min', factor=0.5, patience=5)
if val_loss < best_val_loss:
    best_val_loss = val_loss
    torch.save(checkpoint, 'best_model.pth')
```

图 3 早停与学习率调度

1. 项目介绍

— 1.4 训练策略与集成学习

我们采用五折交叉验证训练 5 个独立模型，每个折使用不同的训练/验证划分。训练中监控验证损失，调整学习率，并在性能不再提升时早停。最后，我们集成 5 个模型的预测结果，这通常比单个模型更稳定、更准确。

消融实验验证：

技术	对 R ² 的提升	说明
完整模型	0.606 (基准)	-
无多任务学习	-12%	证明多任务的有效性
无 Mixup	-6%	数据增强的重要性
无 TTA	-9%	推理优化的价值
单模型	-11%	集成学习的优势

1. 项目介绍

— 1.5 算法性能验证

我们的算法在验证集上达到 $R^2=0.606$ ，总生物量预测误差仅 15.8%。消融实验证明了各组件的重要性：多任务学习贡献最大，提升 12% 的 R^2




图 4 第一折




图 5 第二折




图 6 第三折




图 7 第四折



图 8 第五折

收敛趋势分析：

训练过程在三阶段均表现稳定

性能指标分析：

R^2 指标：验证集 R^2 从初始负值稳步提升至 0.45-0.60

误差指标：RMSE 从 33-39 降至 15-19，MAE 从 22-27 降至 10-13，降幅均超过 50%

稳定性验证： 五折训练均呈现相似收敛模式与性能区间

1. 项目介绍

— 1.6 结果展示

初始阶段（Epoch 1-10） 模型快速学习，损失骤降；中期阶段（Epoch 11-30） 验证损失波动下降， R^2 转正至 0.2-0.4；后期阶段（Epoch 31-结束） 训练损失降至 60-80，验证损失平稳，最佳验证轮次出现在 35-42 轮，早停在 46-53 轮触发，有效防止过拟合。

验证集 R^2 稳步提升表明模型对目标变量具有有效解释力。

RMSE 降幅证明模型预测准确性显著提升。

五折训练均呈现相似收敛模式与性能区间，验证了训练策略与模型架构的稳定性与鲁棒性。

多任务协同学习： 共享特征+多任务头设计

智能损失函数： 目标感知的加权 MSE

混合增强策略： Mixup + 传统增强

双重集成： 交叉验证模型集成 + TTA 集成

1. 项目介绍

— 1.7 算法创新点总结：

我们的创新在于多任务协同学习、智能损失函数、混合增强策略和双重集成技术。

感谢聆听

1. 项目介绍

— 1.7 算法创新点总结：

感谢大家的聆听，谢谢大家

Q&A

1. 项目介绍

— 1.7 算法创新点总结：

接下来是问答环节，欢迎大家提问